

Distributed Representations of Words and Phrases and their Compositionality

<https://s3-us-west-2.amazonaws.com/secure.notion-static.com/925cff5b-0973-47e4-be4d-6766fd79fda8/5021-distributed-representations-of-words-and-phrases-and-their-compositionality.pdf>

1. Introduction

- Distributed representation

強調的是每個詞都對應著一個低維（例如100維）的向量，這個詞的“詞義”或者這個詞與其他詞的關係就蘊含在這個向量的不同維度中，例如題圖中例子，但是我們一般並不知道每個維度對應著什麼含義。和one hot encoding形成對比。

- Skip-gram

- ▼ Original skip gram


$$\frac{1}{T} \sum_{t=1}^T \sum_{-c \leq j \leq c, j \neq 0} \log p(w_{t+j} | w_t)$$

Skip-gram 就是要maximize這個式子

假設有T個training words, c 是training context的大小。c越大就有越多的training examples，但相對的訓練時間就比較長，而Skip-gram的目標就是maximize上面的式子。


$$p(w_O | w_I) = \frac{\exp(v'_{w_O}{}^T v_{w_I})}{\sum_{w=1}^W \exp(v'_w{}^T v_{w_I})}$$

v_w 代表著 "input" vector representations of w, v'_w 則代表 "output" vector representations of w. "input" vector representation 則是 W 中一個row的weight. 而"output" vector representation代表W中一個column的weight.



▼ Hierarchical Softmax

原先softmax需要對所有vocabulary加總，很花時間。



The probability of the word Football will be

$$P_{\theta}^h(w = \text{Football}) = P_{\theta}^h(0 \rightarrow 1)P_{\theta}^h(1 \rightarrow 3)P_{\theta}^h(3 \rightarrow \text{Football})$$

走左子樹的機率:

$$p(n, left) = \frac{1}{1 + e^{-x}} = \sigma(x)$$

走右子樹的機率:

$$p(n, right) = 1 - \frac{1}{1 + e^{-x}} = \frac{e^{-x}}{1 + e^{-x}} = \frac{1}{1 + e^x} = \sigma(-x)$$

$$p(w|w_I) = \prod_{j=1}^{L(w)-1} \sigma \left(\mathbb{I}[n(w, j+1) = \text{ch}(n(w, j))] \cdot v'_{n(w, j)}{}^\top v_{w_I} \right)$$

而在這邊我們判斷走左或右子樹的機率，是根據到目前這個node，與原先的word的cosine similarity。再將機率連成得到的機率。

▼ Negative sample

要解決的問題是：當我們採取一個pair的時候，例如(fox, quick)。則quick的機率為1，其他的為0，透過negative sample，我們隨機採取幾個negative的詞，來更新我們的頻率。

將原本要算的 $\log P(w_O|w_I)$ 代換成

$$\log \sigma(v'_{w_O}{}^\top v_{w_I}) + \sum_{i=1}^k \mathbb{E}_{w_i \sim P_n(w)} \left[\log \sigma(-v'_{w_i}{}^\top v_{w_I}) \right]$$

第一項的意思根據 "input" 以及 "output" vector 的 cosine similarity。而後面那項的意義就是避免noise抽取出來的word的vector與原先的"input" vector越不像越好。有點像變成二分類的問題，要把noise跟原本的分布拉的越開越好。

在實作上，我們根據字詞出現的頻率來選擇negative sample。每個字被選擇的機率為

$$P(w_i) = \frac{f(w_i)^{0.75}}{\sum_{j=0}^n f(w_j)^{0.75}}$$

其中0.75是來自實驗的結果。

[译] Noise Contrastive Estimation

英文原文来自于我自己的博客，感谢自然语言处理百科全书的邀稿。简介在一个以 θ 为参数的神经网络语言模型中，给予一定的语境 h ，我们通常使用softmax函数来预测下一个词的分布。这里我们把预测下一个词的条...

[知 https://zhuanlan.zhihu.com/p/76568362](https://zhuanlan.zhihu.com/p/76568362)

Noise classifier

似然值→

如何理解似然函数？

似然函数在统计推断中意义重大，但是不是很理解为什么定义是 $L(\theta|x)=f(x|\theta)$ 。我们在似然函数和概率密度...

[知 https://www.zhihu.com/question/54082000](https://www.zhihu.com/question/54082000)

NCE notes

Figure 1 illustrates the Vanilla Skip-Gram model. It shows a word embedding matrix W (10x3) and a bias vector b (10x1). These are combined into a matrix $W+b$ (10x4). This matrix is then multiplied by a word vector w (4x1) to produce a score s (1x1). The score s is then passed through a sigmoid function to produce the probability p (1x1).

 https://aegis4048.github.io/optimize_computational_efficiency_of_skip-gram_with_negative_sampling

One way to generate a good quality word embedding from a corpus is using Word2Vec - CBOW or Skip-gram model. Both models have a few things in common: The training samples consisted of a pair of words selected based on proximity of occurrence. The last layer in the network was

- ▼ subsampling of frequent words

$$P(w_i) = 1 - \sqrt{\frac{t}{f(w_i)}}$$

Distributed Representations of Words and Phrases and their Compositionality